

多模态人体动作对齐研究及其应用

东南大学计算机科学与工程学院

报告人：王洪松

主页：<https://hongsong-wang.github.io/>

邮箱：hongsongwang@seu.edu.cn

<https://hongsong-wang.github.io/>

- 动作研究背景
- 动作-文本对齐
- 问题及未来方向

<https://hongsong-wang.github.io/>


- 动作研究背景
- 动作-文本对齐
- 问题及未来方向

万物皆流（运动）

- 运动是绝对的

- 古希腊哲学家赫拉克利特提出“万物皆流”的思想，经典比喻“人不能两次踏进同一条河流”
- 宇宙万物不存在绝对静止，始终处于永恒的运动与变化之中

<https://hongsong-wang.github.io/>




人体动作为原始语言

• 动作的本源价值


<https://hongsong-wang.github.io/>

- 人体动作是比语言更原始、更根本的交流方式
- 人体动作对齐的本质，让AI学会理解与生成这种“动作语言”



目标 VS 动作

- 目标理解：关注目标是什么，不关注如何运动
- 动作理解：既关注目标，也关注其如何运动



目标理解

目标：Baymax

动作理解

动作：
Baymax 侧身站立、
Baymax 伸展手臂、
Baymax 抬高手臂

人体动作数据集

数据集	时间	规模	总时长	主要任务	特点
BABEL	CVPR 2021	28K	43h	识别、定位、生成	帧级语言标签
Ego4D	CVPR 2022	3850K	3670+h	识别、预测	第一人称视频
Motion-X	NeurIPS 2023	81,100		生成、理解	Whole-body 数据集
Ego-Exo4D	CVPR 2024		1286h	识别、评估	多视角技能动作数据集
Motion-X++	2025	120.5K		生成	新增 RGB 视频、音频、多模态

github.io/



应用需求

- 智能监控与公共安全：异常行为检测、人流分析
- 健康医疗与体育训练：个性化训练



应用需求

- 数字娱乐与内容创作：游戏开发、影视制作、虚拟社交
- 机器人与工业自动化：机器人模仿人、人机交互




人体动作共有多少类别？

动作类别：层次化结构

- 人体动作类别的多层级结构

<https://hongsong-wang.github.io/>

- 元素层：最基础的原子动作
- 组合层：由多个原子动作按时序串联的连贯动作
- 事件层：由多组动作组合构成的复杂活动



动作类别：模糊性与语境依赖


- 模糊性：缺乏绝对的类别边界
 - 与具有明确物理属性的物体不同，动作的定义往往没有绝对共识（例如“慢跑”与“跑步”之间不存在严格的边界）
- 语境依赖性：场景决定语义
 - 同一肢体动作在不同语境下可表达完全不同的含义
- 无法用有限的离散类别穷尽所有人体动作

人体动作建模：三个层次


• 人体动作的语义的多层级结构

- 观测：利用RGB相机、深度传感器等设备捕捉运动视频流
- 状态：从视频中提取人体骨骼关键点及姿态等运动学特征
- 机理：探究骨骼肌肉的动力学与神经控制机制，解析如何驱动动作

<https://hongsong-wang.github.io/>



动作-文本对齐



<https://hongsong-wang.github.io/>


- 动作研究背景
- **动作-文本对齐**
- 问题及未来方向

半在线偏好优化

• 基于偏好优化的动作生成

<https://hongsong-wang.github.io/>

- 偏好优化在动作生成领域的相关研究很少
- 直接偏好优化通过偏好数据微调生成模型以对齐人类偏好
- 构建基于偏好优化的文生动作模型，生成高质量且符合人类偏好的动作




Tan, Xiaofeng, **Hongsong Wang***, Xin Geng, and Pan Zhou. "SoPo: Text-to-motion generation using semi-online preference optimization." Advances in Neural Information Processing Systems 38 (2025): 60714-60747.

半在线偏好优化

• 基于半在线偏好优化的人体动作生成

<https://hongsong-wang.github.io/>

- 离线偏好优化容易过拟合，筛选出非偏好动作样本
- 在线偏好优化生成多样化样本，偏好差异不足，遗漏低概率偏好动作
- 提出半在线偏好优化理论，实现更稳定、泛化性更强的偏好对齐




Tan, Xiaofeng, **Hongsong Wang***, Xin Geng, and Pan Zhou. "SoPo: Text-to-motion generation using semi-online preference optimization." Advances in Neural Information Processing Systems 38 (2025): 60714-60747.


半在线偏好优化

HumanML3D数据集上基于偏好优化的文生动作实验结果

Methods	Time*	R-Precision $\uparrow$			MM Dist $\downarrow$	Diversity $\rightarrow$	FID $\downarrow$
		Top 1	Top 2	Top 3			
Real	-	0.511 $\pm$ 0.003	0.703 $\pm$ 0.003	0.797 $\pm$.002	2.974 $\pm$ 0.008	9.503 $\pm$ 0.065	0.002 $\pm$ 0.000
MLD [1]	+0 X	0.453 $\pm$ 0.003	0.679 $\pm$ 0.003	0.755 $\pm$ 0.003	3.292 $\pm$ 0.010	9.793 $\pm$ 0.072	0.459 $\pm$ 0.011
+ MoDiPO-T [9]	+121K X	0.455 $\pm$ 0.002	0.682 $\pm$ 0.003	0.758 $\pm$ 0.002	3.267 $\pm$.010	9.747 $\pm$ 0.073	0.303 $\pm$ 0.031
+ MoDiPO-G [9]	+121K X	0.452 $\pm$ 0.003	0.678 $\pm$ 0.003	0.753 $\pm$ 0.003	3.294 $\pm$ 0.010	9.702 $\pm$.075	0.281 $\pm$ 0.031
+ MoDiPO-O [9]	-	0.406 $\pm$ 0.003	0.609 $\pm$ 0.003	0.677 $\pm$ 0.003	3.701 $\pm$ 0.013	9.241 $\pm$.079	0.276 $\pm$ 0.007
+ SoPo (Ours)	+20 X	0.463 $\pm$ 0.003	0.682 $\pm$ 0.003	0.763 $\pm$ 0.003	3.185 $\pm$ 0.012	9.525 $\pm$ 0.065	0.374 $\pm$ 0.007
MDM [13]	+0 X	0.418 $\pm$ 0.005	0.604 $\pm$ 0.005	0.703 $\pm$ 0.005	3.658 $\pm$ 0.025	9.546 $\pm$ 0.066	0.501 $\pm$ 0.037
+ MoDiPO-T [9]	+121K X	0.421 $\pm$ 0.006	0.635 $\pm$ 0.005	0.706 $\pm$ 0.004	3.634 $\pm$.026	9.531 $\pm$ 0.073	0.451 $\pm$ 0.031
+ MoDiPO-G [9]	+121K X	0.420 $\pm$ 0.006	0.632 $\pm$ 0.005	0.704 $\pm$ 0.001	3.641 $\pm$ 0.025	9.495 $\pm$ 0.071	0.486 $\pm$ 0.031
MDM (fast) [13]	+0 X	0.455 $\pm$ 0.006	0.645 $\pm$ 0.007	0.749 $\pm$ 0.004	3.304 $\pm$ 0.023	9.948 $\pm$ 0.084	0.534 $\pm$ 0.052
+ SoPo (Ours)	+60 X	0.479 $\pm$ 0.006	0.674 $\pm$.005	0.770 $\pm$ 0.006	3.208 $\pm$ 0.025	9.906 $\pm$.083	0.480 $\pm$ 0.046



SoPo 让模型更懂文本的空间语义



通过用户打分实验，SoPo动作生成结果更符合人类偏好


Tan, Xiaofeng, **Hongsong Wang***, Xin Geng, and Pan Zhou. "SoPo: Text-to-motion generation using semi-online preference optimization." Advances in Neural Information Processing Systems 38 (2025): 60714-60747.

动作-文本重对齐

• 基于奖励优化的动作生成

- 现有文本-动作对齐研究主要微调生成模型，缺乏处理带噪动作的能力
- 动作对齐偏差问题应在动作生成阶段解决，而不是依赖后处理
- 动作生成与动作检索虽然紧密关联，但被独立研究

<https://hongsong-wang.github.io/>




Wanjiang Weng, Xiaofeng Tan, Junbo Wang, Guo-Sen Xie, Pan Zhou, **Hongsong Wang***. "ReAlign: Text-to-Motion Generation via Step-Aware Reward-Guided Alignment." AAAI Conference on Artificial Intelligence. 2026.

动作-文本重对齐

• 基于奖励引导的动作与文本重对齐

<https://hongsong-wang.github.io/>

- 奖励模型包含文本对齐和动作对齐，分别保障语义一致性和动作真实度
- 奖励模型即插即用，无需微调可集成到任意动作扩散模型



理论证明:

文本对齐和动作对齐奖励共同构建的梯度，会逐步影响扩散模型去噪过程，将采样轨迹导向更贴合目标动作语义的分布

动作-文本重对齐

HumanML3D数据集上文生动作实验结果

<https://hongsong-wang.github.io/>

Method	R Precision $\uparrow$			FID $\downarrow$	MM Dist $\downarrow$	Diversity $\rightarrow$
	Top 1	Top 2	Top 3			
Real	0.511	0.703	0.797	0.002	2.974	9.503
T2M (2022a)	0.455 $\pm$ 0.002	0.636 $\pm$ 0.003	0.736 $\pm$ 0.003	1.087 $\pm$ 0.002	3.347 $\pm$ 0.008	9.175 $\pm$ 0.002
MDM (2023)	0.455 $\pm$ 0.006	0.645 $\pm$ 0.007	0.749 $\pm$ 0.006	0.489 $\pm$ 0.047	3.330 $\pm$ 0.25	9.920 $\pm$ 0.083
T2M-GPT (2023a)	0.492 $\pm$ 0.003	0.679 $\pm$ 0.002	0.775 $\pm$ 0.002	0.141 $\pm$ 0.005	3.121 $\pm$ 0.009	9.722 $\pm$ 0.082
ReMoDiffuse (2023b)	0.510 $\pm$ 0.005	0.698 $\pm$ 0.006	0.795 $\pm$ 0.004	0.103 $\pm$ 0.004	2.974 $\pm$ 0.016	9.018 $\pm$ 0.75
Mo.Diffuse (2024)	0.491 $\pm$ 0.001	0.681 $\pm$ 0.001	0.775 $\pm$ 0.001	0.630 $\pm$ 0.001	3.113 $\pm$ 0.001	9.410 $\pm$ 0.049
OMG (2024)	-	-	0.784 $\pm$ 0.002	0.381 $\pm$ 0.008	-	9.657 $\pm$ 0.085
MotionLCM (2025)	0.502 $\pm$ 0.003	0.698 $\pm$ 0.002	0.798 $\pm$ 0.002	0.304 $\pm$ 0.012	3.012 $\pm$ 0.007	9.607 $\pm$ 0.066
Mo.Mamba (2025b)	0.502 $\pm$ 0.003	0.693 $\pm$ 0.002	0.792 $\pm$ 0.002	0.281 $\pm$ 0.011	3.060 $\pm$ 0.000	9.871 $\pm$ 0.084
CoMo (2024)	0.502 $\pm$ 0.002	0.692 $\pm$ 0.007	0.790 $\pm$ 0.002	0.262 $\pm$ 0.004	3.032 $\pm$ 0.015	9.936 $\pm$ 0.066
ParCo (2025)	0.515 $\pm$ 0.003	0.706 $\pm$ 0.003	0.801 $\pm$ 0.002	0.109 $\pm$ 0.005	2.927 $\pm$ 0.008	9.576 $\pm$ 0.088
MARDM (2024)	0.500 $\pm$ 0.004	0.695 $\pm$ 0.003	0.795 $\pm$ 0.003	0.114 $\pm$ 0.007	-	-
MG-MotionLLM (2025b)	0.516 $\pm$ 0.002	0.706 $\pm$ 0.002	0.802 $\pm$ 0.003	0.303 $\pm$ 0.010	2.952 $\pm$ 0.009	9.960 $\pm$ 0.073
EnergyMoGen (2025)	0.526 $\pm$ 0.003	0.718 $\pm$ 0.003	0.815 $\pm$ 0.002	0.176 $\pm$ 0.006	2.931 $\pm$ 0.007	9.500 $\pm$ 0.091
MLD (2023b)	0.481 $\pm$ 0.003	0.673 $\pm$ 0.003	0.772 $\pm$ 0.002	0.473 $\pm$ 0.013	3.196 $\pm$ 0.010	9.724 $\pm$ 0.082
w/ ReAlign (Ours)	0.567 $\pm$ 0.003 (+17.9%)	0.759 $\pm$ 0.003 (+12.8%)	0.848 $\pm$ 0.003 (+9.8%)	0.195 $\pm$ 0.005 (+58.8%)	2.704 $\pm$ 0.007 (+15.4%)	9.474 $\pm$ 0.068 (+86.9%)
MLD++(2025)	0.548 $\pm$ 0.003	0.738 $\pm$ 0.003	0.829 $\pm$ 0.002	0.073 $\pm$ 0.003	2.810 $\pm$ 0.008	9.658 $\pm$ 0.089
w/ ReAlign (Ours)	0.572 $\pm$ 0.002 (+4.4%)	0.764 $\pm$ 0.002 (+3.5%)	0.852 $\pm$ 0.001 (+2.8%)	0.055 $\pm$ 0.003 (+24.7%)	2.648 $\pm$ 0.008 (+5.8%)	9.478 $\pm$ 0.055 (+83.9%)

Wanjiang Weng, Xiaofeng Tan, Junbo Wang, Guo-Sen Xie, Pan Zhou, **Hongsong Wang***. "ReAlign: Text-to-Motion Generation via Step-Aware Reward-Guided Alignment." AAAI Conference on Artificial Intelligence. 2026.

动作-文本重对齐

文本-动作检索的实验结果（包括文本检索动作和动作检索文本两个任务）


	Methods	Noise	Text-Motion Retrieval↑					Motion-Text Retrieval↑				
			R@1	R@2	R@3	R@5	R@10	R@1	R@2	R@3	R@5	R@10
HumanML3D	TEMOS (2022)	✗	40.49	53.52	61.14	70.96	84.15	39.96	53.49	61.79	72.40	85.89
	T2M (2022b)	✗	52.48	71.05	80.65	89.66	96.58	52.00	71.21	81.11	89.87	<u>96.78</u>
	TMR (2023)	✗	67.16	81.32	86.81	91.43	95.36	67.97	81.20	86.35	91.70	95.27
	LaMP (2025)	✗	67.18	81.90	87.04	92.00	95.73	68.02	82.10	87.50	92.20	96.90
	ReAlign (ours)	✓	67.59	82.24	87.44	<u>91.97</u>	<u>96.28</u>	68.94	82.86	87.95	92.44	<u>96.28</u>
KIT-ML	TEMOS (2022)	✗	43.88	58.25	67.00	74.00	84.75	41.88	55.88	65.62	75.25	85.75
	T2M (2022b)	✗	42.25	62.62	75.12	87.50	96.12	39.75	62.75	73.62	86.88	95.88
	TMR (2023)	✗	49.25	69.75	78.25	87.88	95.00	50.12	67.12	76.88	88.88	94.75
	ReAlign (ours)	✓	52.84	71.66	82.96	91.19	97.59	52.98	72.87	84.38	92.61	96.87

逐步奖励微调动作生成

• 可微奖励对齐扩散模型

- 利用可微奖励直接对齐扩散模型存在两大问题：优化效率低下且粒度粗糙、内存消耗过高
- 从理论和实验层面揭示核心原因：去噪轨迹中不同时间步之间的递归依赖关系

<https://hongsong-wang.github.io/>




逐步奖励微调动作生成

• 高效逐步奖励微调动作生成模型

- 去噪步骤中单独微调扩散模型，而非对整条轨迹进行优化，消除了梯度递归依赖关系
- 实现了密集且细粒度的动作对齐优化，并降低了内存消耗

<https://hongsong-wang.github.io/>



Xiaofeng Tan, Wanjiang Weng, Haodong Lei, **Hongsong Wang***. “EasyTune: Efficient Step-Aware Fine-Tuning for Diffusion-Based Motion Generation”. International Conference on Learning Representations, 2026.

逐步奖励微调动作生成

HumanML3D数据集上文生动作实验结果

<https://hongsong-wang.github.io/>

Method	R Precision $\uparrow$			FID $\downarrow$	MM Dist $\downarrow$	Diversity $\rightarrow$
	Top 1	Top 2	Top 3			
Real	0.511	0.703	0.797	0.002	2.974	9.503
TM2T (Guo et al., 2022b)	0.424 ± 0.003	0.618 ± 0.003	0.729 ± 0.002	1.501 ± 0.017	3.467 ± 0.011	8.589 ± 0.076
T2M (Guo et al., 2022a)	0.455 ± 0.002	0.636 ± 0.003	0.736 ± 0.003	1.087 ± 0.002	3.347 ± 0.008	9.175 ± 0.002
MDM (Tevet et al., 2023)	0.455 ± 0.006	0.645 ± 0.007	0.749 ± 0.006	0.489 ± 0.047	3.330 ± 0.025	9.920 ± 0.083
T2M-GPT (Zhang et al., 2023a)	0.492 ± 0.003	0.679 ± 0.002	0.775 ± 0.002	0.141 ± 0.005	3.121 ± 0.009	9.722 ± 0.082
ReMoDiffuse (Zhang et al., 2023b)	0.510 ± 0.005	0.698 ± 0.006	0.795 ± 0.004	0.103 ± 0.004	2.974 ± 0.016	9.018 ± 0.075
AttT2M (Zhong et al., 2023)	0.499 ± 0.003	0.690 ± 0.002	0.786 ± 0.002	0.112 ± 0.006	3.038 ± 0.007	9.700 ± 0.090
MotionDiffuse (Zhang et al., 2024a)	0.491 ± 0.001	0.681 ± 0.001	0.775 ± 0.001	0.630 ± 0.001	3.113 ± 0.001	9.410 ± 0.049
MotionLCM (Dai et al., 2024)	0.502 ± 0.003	0.698 ± 0.002	0.798 ± 0.002	0.304 ± 0.012	3.012 ± 0.007	9.607 ± 0.066
MotionMamba (Zhang et al., 2024b)	0.502 ± 0.003	0.693 ± 0.002	0.792 ± 0.002	0.281 ± 0.011	3.060 ± 0.000	9.871 ± 0.084
CoMo (Huang et al., 2024)	0.502 ± 0.002	0.692 ± 0.007	0.790 ± 0.002	0.262 ± 0.004	3.032 ± 0.015	9.936 ± 0.066
ParCo (Zou et al., 2024)	0.515 ± 0.003	0.706 ± 0.003	0.801 ± 0.002	0.109 ± 0.005	2.927 ± 0.008	9.576 ± 0.088
SoPo (Tan et al., 2025)	0.528 ± 0.005	0.722 ± 0.004	0.827 ± 0.004	0.174 ± 0.005	2.939 ± 0.011	9.584 ± 0.074
MLD (Chen et al., 2023) (Base Model)	0.504 ± 0.002	0.698 ± 0.003	0.796 ± 0.002	0.450 ± 0.011	3.052 ± 0.009	9.634 ± 0.064
w/ EasyTune (Ours)	0.581 ± 0.003 $+15.3\%$	0.769 ± 0.002 $+10.2\%$	0.855 ± 0.002 $+7.4\%$	0.132 ± 0.005 $+70.7\%$	2.637 ± 0.007 $+13.6\%$	9.465 ± 0.075 $+0.09$
MLD++ (Dai et al., 2025) (Base Model)	0.548 ± 0.003	0.738 ± 0.003	0.829 ± 0.002	0.073 ± 0.003	2.810 ± 0.008	9.658 ± 0.089
w/ EasyTune (Ours)	0.591 ± 0.004 $+7.8\%$	0.777 ± 0.002 $+5.3\%$	0.859 ± 0.002 $+3.6\%$	0.069 ± 0.003 $+6.8\%$	2.592 ± 0.008 $+7.8\%$	9.705 ± 0.086 -0.06

Xiaofeng Tan, Wanjiang Weng, Haodong Lei, **Hongsong Wang***. “EasyTune: Efficient Step-Aware Fine-Tuning for Diffusion-Based Motion Generation”. International Conference on Learning Representations, 2026.

<https://hongsong-wang.github.io/>


- 动作研究背景
- 动作-文本对齐
- **问题及未来方向**

开放词汇人体行为理解

- 开放词汇人体行为理解还没解决

<https://hongsong-wang.github.io/>

- 当前模型仅能识别预定义的动作类别，无法应对真实场景的行为描述
- 缺乏大规模高质量动作数据集
- 开放环境下人体姿态估计误差大、骨架数据噪声极高



复杂人体动作生成

• 复杂人体动作生成的质量问题

<https://hongsong-wang.github.io/>

- 长尾动作数据不足，复杂动作生成能力弱
- 动作生成模型针对武术、舞蹈等复杂长时序动作，容易生成帧肢体衔接僵硬、穿模等违反物理规律的结果
- 人体运动学错误，骨骼拉伸、关节超限，缺少运动学约束
- 时空一致性和物理合理性



统一单人/多人行为理解

• 统一单人/多人行为理解模型

<https://hongsong-wang.github.io/>

- 单人行为识别与多人交互理解依赖独立架构，缺乏统一特征空间
- 个体与群体行为的通用特征空间，实现统一单人/多人行为理解
- 提升场景泛化性，为智慧安防、人机交互等领域提供决策支撑

统一行为理解模型

actions



interactions



group
activities



统一单人/多人动作生成

• 多角色协同动作生成

<https://hongsong-wang.github.io/>

- 多人交互动作生成需要处理角色间的空间位置关系、行为交互逻辑及动作的自然协同
- 多角色动态交互的生成，突破单主体限制
- 赋能游戏NPC智能行为生成、影视剧情自动编排及虚拟人互动场景制作，大幅降低制作成本，提升虚拟世界沉浸感



视频-动作-文本对齐

- 视频-动作-文本多模态理解与生成闭环

<https://hongsong-wang.github.io/>

- 当前研究局限于视频-文本或动作-文本的双模态对齐，缺乏对视频、动作和语言的全局统一对齐模型
- 实现“视频→动作→文本”和“文本→动作→视频”的双向闭环




文本-动作-机器人控制

- 端到端的文本-动作-机器人控制

<https://hongsong-wang.github.io/>

- 实现从人类自然语言指令到机器人实体物理行动的直接映射
- 语言理解：解析用户指令语义与意图，拆解任务与环境要素
- 动作规划：生成可行运动轨迹，分解为连续基础动作序列
- 运动控制：转化为底层关节信号，驱动机器人完成物理交互





历年顶会论文门户
网站CV_Paper_Portal



人体动作研究组
微信公众号

谢谢！ 欢迎讨论

主页: <https://hongsong-wang.github.io/>

邮箱: hongsongwang@seu.edu.cn